Метрики и план проверки Trace

Протокол будущего эксперимента

Метрики пользы

Метрика	Расчёт и единица	Интерпретация
Активное время	Минуты на весь разбор, включая исправления OCR и проверку подсказок	Медиана для типичного опыта; среднее для экономики
Точность замечаний	Верные замечания / все выданные замечания	Долю ложных замечаний проверяем отдельно
Полнота замечаний	Найденные проблемы / проблемы в экспертном эталоне	Критичные пропуски учитываем отдельно
Повторные уточнения	Обращения с повторным запросом из-за неполноты / завершённые обращения когорты	Сравниваем одинаковый период наблюдения
Использование	Обращения, прошедшие через Trace / подходящие обращения	Не смешиваем с долей применимости

На сайте предложены ориентиры: −25% к медианному активному времени, −20% к доле повторных уточнений и 10–20 сотрудников одного процесса. Это предложения команды для обсуждения, а не согласованные пороги, фактическая выборка или достигнутые результаты. Снижение доли повторных уточнений понимаем как относительное, не как 20 процентных пунктов.

Если знаменатель равен нулю, метрика неприменима. Число сотрудников не заменяет число независимых комплектов. Для денежного расчёта используем среднюю экономию минут; целевое изменение медианы нельзя напрямую подставлять в финансовую модель.

Дизайн сравнения

До эксперимента

Согласовать один профиль с экспертом банка. Подготовить разрешённые обезличенные комплекты и экспертный эталон полей и замечаний. Определить серьёзность ошибок, единицу наблюдения, пороги качества, выборку и исключения до измерений.

Порядок работы

Обучение проходит на отдельном наборе. Участники решают сопоставимые задачи привычным способом и с Trace; порядок меняется между участниками. Пары комплектов сопоставляем по сложности. Повторный разбор запомнившегося кейса не считаем независимым наблюдением.

Измерение

Фиксируем активную работу, ожидание и ручные исправления отдельно. Время проверки OCR и подготовки окончательного запроса включаем в трудозатраты. Для пар сравниваем разницу времени; публикуем среднее, медиану, разброс и число независимых наблюдений. Не приписываем весь эффект повторных запросов только интерфейсу.

Техническое подтверждение

В репозитории опубликован отчёт на 200 синтетических комплектах в 10 категориях и журнал 16 Python-тестов. Этот набор проверяет узкие текстовые правила, а не OCR и не банковское качество. Тестовый отчёт не заменяет эксперимент с сотрудниками.

Решение о пилоте

Продолжение возможно при подтверждённой проблеме, приемлемом качестве, самостоятельном выполнении сценария и положительном эффекте после затрат. Итоги публикуем вместе с пропусками, исключёнными случаями и ограничениями.